

~ WEEK 2

今までの線形モデルだと、変数一つにしか対応することができない。

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

特徴の入力を x としていたが

$x_1, x_2, x_3, x_4, \dots$ とする。

$x_2^{(3)}$ \Leftarrow 3番目のサンプル
2個目の特徴

仮説式を複数対応すると、

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4 \\ \dots + \theta_n x_n$$

となる。

$x_0 = 1$ とすると、 $\theta_0 x_0$ がバリエーションだと考える事ができる。

これを 重回帰 (多変量の線形回帰) と呼ぶ。

最急降下法は

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta_0}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta_1}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

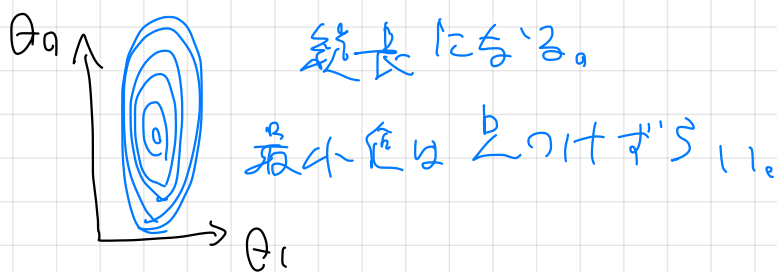
$$\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta_2}(x^{(i)}) - y^{(i)}) x_2^{(i)}$$

となる。

増えただけ？

Scaling Feature

あまりにバラバラに差があると、等高線図が乱れ、大局的な最小値を見つけるのは困難になる。



$$-100 \leq \theta_0 \leq 100 \quad 0 \leq \theta_1 \leq 1$$

$\theta_0 / 100$ などで、 $100 \times x$ をスケールすると、
計算しやすい。 x_2 1 x_3 1


$$-1 \leq x_i \leq 1$$

にあてるとよい。

$38 \leq x \leq 50$ のときは？


$$\frac{x - 38}{20}$$

とするとよい。




こんな感じのデータセットに

上手く合う線形モデルは？



二次関数？



下降していくもの。

三次関数？

合、このまゝはいえりい。

パラメータに重みをつける。

$$x_1 = (\text{パラメータ})^1$$

$$x_2 = (\text{パラメータ})^2$$

$$x_3 = (\text{パラメータ})^3$$

とすること、

とできる。

※ この方法を行う時は特に
スケールिंगに気をつける必要
がある。

正規方程式

$$\theta = (X^T X)^{-1} X^T y \dots \textcircled{1}$$

$$X' = X^T$$

octave : `pinv(X' * X) * X' * y`

↓

- 全ての局所的最小値が出る。

正規方程式では スケーリング はしないでよい。

最急降下法 と 正規方程式 とどちらを使う

べきか。

- ・ α を指定する必要がある。
- ・ 反復回数が多い。
- ・ 特徴値 n の数が多い時には 上手く機能する。

・ α を指定する必要がない。

・ 反復は必要ない。

・ 計算が必要 \Rightarrow ①

・ n が多いと 上手く機能しない。

8836 - 4761

= 4075

1 2
3 4
5 6

1 1
2 2

$\begin{pmatrix} 5 & 5 \\ 1 & 1 \\ 17 & 17 \end{pmatrix}$

7

Octaveにおける線形回帰の仮説

- ベクトル化せずに全ての θ にかける

```
prediction = 0.0;
```

```
for j = 1 : n + 1,
```

```
    prediction = prediction +  
        theta(j) * x(j)
```

```
end;
```

- ベクトル化してライブラリを利用

```
prediction = theta' * x;
```



Octave では転置の意味

$$\text{theta}' = \text{theta}^T$$

あかたこと

$\theta^T x$ は 二つのベクトル値

(θ はベクトルじゃない ときもある)

$$\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}$$

$$\begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

仮定式は $h(\theta; x) = \theta_0 + \theta_1 x_1 + \dots$
なので、

$$\theta^T = \begin{bmatrix} \theta_0 & \theta_1 & \theta_2 & \theta_3 \end{bmatrix} * \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

この場合はただの行列の積

Octave τ' は、

$\text{sum}(V \cdot^* W)$:

$\gamma \neq 3 \subset \gamma \tau'$,

$$\begin{array}{|c|} \hline \gamma_0 \\ \hline \gamma_1 \\ \hline \gamma_2 \\ \hline \gamma_3 \\ \hline \end{array}$$

$$\begin{array}{|c|} \hline w_0 \\ \hline w_1 \\ \hline w_2 \\ \hline w_3 \\ \hline \end{array}$$

\cdot^* は

$\mathbb{R} \cup i\mathbb{R} \rightarrow \mathbb{R} \pm$
 τ' 積

$\mathbb{R} \cup i\mathbb{R} \subset \gamma \tau' \subset \mathbb{R}$ 。

700 グラミニニグ 課題 1

又略 x 7

JUMC) ?

$$J_{\theta} = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

11

$$J_{\theta}(x) = h_{\theta}(x) + \text{~~~~~} ?$$

Compute Cost において、最急降下法を用いて、この
の 12 コスト関数が収束した。なぜ？

→ $\theta_0 < \theta_1 < \dots$ として、
答えではない ... ?

gradient.m は iteration の数だけ呼び出されて
いる、正しい？

。偏微分を 700 グラミニニグ で記述する方法は？

Gradient descent algorithm


repeat until convergence {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$


$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

}

$$\frac{\partial}{\partial \theta_0} \frac{1}{2m} \sum_{i=1}^m (\underbrace{h_{\theta}(x^{(i)}) - y^{(i)}}_{\text{~~~~~}})^2$$



× が y となるデータに
青線 (線形モデル) をひきたり。





こんなかんじの線形モデルがほしい。

$$h\theta(x) = \theta_0 + \theta_1 x \quad (\text{式})$$

← なんでほしいの?

線形モデルが得られると、


x から y を推定できる。



どうや、て線を引かせる?

$$h_{\theta}(x) = \theta_0 + \theta_1 x \quad (\text{単回帰})$$

において、(Hypothesis)



機械的に正しい $h_{\theta}(x)$ を得るのは難しい。(何を基準にして線形モデルを描くかを定める)


そこで、コスト関数を使う。

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (\underbrace{h_{\theta}(x^{(i)}) - y^{(i)}}_{\text{誤差}})^2$$

- 。 m はデータのテーブル数 (データ総数)
- 。 Hypothesis - 実際のデータ (誤差量)
- 。 最小二乗法とかいうやつ

(なんで二乗するのかわかん...)

コスト関数で、どれくらいまちがった
線を引きしてるのかはわかった。




$h\theta(x)$ と x の距離が一番近い (小さい)
状態になる新形モデルを探す。

その方法として、最急降下法を使う。
(Gradient Descent)

$$\theta_j := \theta_j - \underbrace{\alpha}_{\text{learning rate}} \underbrace{\frac{\partial}{\partial \theta_j}}_{\text{微分}} J(\theta_0, \theta_1)$$

・ ラーニングレート

・ 微分



適当な α から
計算を始めて、
前の地点から
傾きを引く。

正規方程式 (Normal equation)

$$\theta = (X^T X)^{-1} X^T y$$

上記の式で数式的に θ を一発で求めることができる。

多項式回帰 (重回帰)

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$$

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 \sqrt{x}$$

変数が一種類 (x のみ) でも、