



week 3

↑
week 2 までは
帰問題


分類問題

- Email がスパムか？
- アカウントがハックされている？
- 患者のがんは悪性？良性？

0 か 1 か？

y が二つのみではない
場合もある。

$$y \in \{0, 1, 2, 3\}$$



ロジスティクス回帰

0 か 1 (まづ) の仮説がほしい。

$$\underline{h_{\theta}(x) = \theta^T x}$$

→ week 2 の  ×  これ

これを

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1 + e^{-z}}$$


* z は実数

$g()$ は sigmoid 関数、または
logistic 関数 と呼ばれている。

これらを組み合わせると、

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

とすることが出来る。



パラメータ θ が必ず $\frac{1}{4}$ になる

y は 1 か 0 にならなくともいいけど
 (ただし、ロジスティクス関数からの返り値は
 0 か 1)。

$$\chi = \begin{bmatrix} \chi_0 \\ \chi_c \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tuner-size} \end{bmatrix}$$

$$h_{\theta}(x) = 0.7$$

70% y は 1 になる。

25% には


30% y は 0 になる。

Logistic Regression

コスト関数

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$





→ y が 0 のときに、
 $h_{\theta}(x)$ が 1 だと
予測した場合は、
痛い、ペナルティ

$$\underline{h_{\theta}(x) = \infty}$$

分類問題だから、

y は常に 0 か 1



Logistic regression cost function

コスト関数をコンパクトにする。

$$\text{Cost}(h(\theta(x)), y) = -y \log(h(\theta(x))) - (1-y) \log(1-h(\theta(x)))$$

y が 0 か 1 かによって項が消える。

これを組み込んで、

$$J(\theta) = -\frac{1}{n} \left[\sum_{i=1}^m y^{(i)} \log h(\theta(x^{(i)})) + (1-y^{(i)}) \log (1-h(\theta(x^{(i)}))) \right]$$

例によつて θ を最小化したいわけではない。

最急降下法 (Gradient Descent)

を使う。

Repeat {

$$\theta_j = \theta_j - \alpha \sum_{i=1}^m (h(\theta(x^{(i)})) - y^{(i)}) x_j^{(i)}$$

}

→ 線形回帰に似てゐる...?

⇓

仮説が $h(x) = \theta^T x$ だと、 $h(\theta(x)) = \frac{1}{1 + e^{-\theta^T x}}$

「にあきか」あっているのて別物。

でも応用が効く。

(「アキ-」に「き」とは ...)

Advanced Optimization algorithm

- 共役勾配法
- BFGS
- L-BFGS

↑

これを学ぶには何日も、何週間も必要

大体の人がソフトウェアのライブラリを利用


コードは

Advanced Optimization 2

復習しよう。




Multi-class classification

3 が複数ある分類



2つの分類?

One-vs-all



$$y \in \{1, 2, \dots, k\}$$

k回分類問題を


252は211。

$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\theta_0 = 6, \quad \theta_1 = 0, \quad \theta_2 = -1$$

$$6 - x_2$$

$$6 = x_2$$



$$-25 + 0.2x_1 + 0.2x_2 \geq 0$$


$$-6 \leq x_1$$

$$0.2x_1 + 0.2x_2 \geq 25$$

$$x_1 \leq 6$$


$$\frac{x_1 + x_2}{0.2} = 5$$

The Problem of Overfitting




$$\theta_0 + \theta_1 x$$

"Underfit"



$$\theta_0 + \theta_1 x + \theta_2 x^2$$


"Just right"



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$


"Overfitting"

$\mathbb{Q} = \mathbb{R}^2 \rightarrow \mathbb{R} \quad (2) \rightarrow \mathbb{R}$




$$h(\mathbf{x}) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

(g = sigmoid function)



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^3 x_2 + \theta_6 x_1^3 x_2 + \dots)$$

Overfitting の回避

1. 特徴数を減らす。

※ 重要な x が無くなると痛い場合がある。

2. パラメータを減らす / 調整する。

※ 正則化と呼ばれる技術

正則化

θ_0 と θ_1 を 0 に近づける。

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h\theta(x^{(i)}) - y^{(i)})^2$$

全てのパラメータを縮める。


⇒ どのパラメータを短かくする λ がわからない。

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h\theta(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

正則化パラメータ

? λ が過剰に大きくなる。
($\lambda = 10^{10}$ とか...)

\Rightarrow under fitting する



※ 書かさない

正則化するときに、ペナルティが課される
のは、 $\theta_1, 2, 3, \dots, n$ のみ。

\hookrightarrow θ_0 は別に用意する。


$$-25 + 0.2x + 0.2y \geq 0$$

$$0.2x + 0.2y \geq 25$$


正則化を加えた

最急降下法で


0 を扱い




plot



Sigmoid



plot



正規化

7 2

実行

week 3

おわり